

Byte Pair Encoding (BPE) یک الگوریتم توکنیزیشن است که برای فشرده‌سازی متن توسعه یافته بود و بعداً توسط OpenAI برای آموزش مدل **GPT-2** و **GPT-3** به‌طور مستقیم استفاده شد.

Character-Level BPE

BPE یک الگوریتم **حریصانه (Greedy Algorithm)** است. این به این معنی است که در هر گام، محلی‌ترین و بهینه‌ترین تصمیم را می‌گیرد (ادغام پرتکرارترین جفت) و این کار را تا رسیدن به هدف نهایی (اندازه واژگان مشخص) ادامه می‌دهد، بدون اینکه به تأثیرات بلندمدت آن فکر کند.

ورودی: یک پیکره (Corpus) از متون و یک عدد صحیح V که اندازه نهایی واژگان مطلوب است.

واژگان پایه: واژگان اولیه شامل تمام کاراکترهای منحصره‌فرد در پیکره است. برای مثال، اگر پیکره فقط شامل "cat" و "car" باشد، واژگان پایه $\{c, a, t, r\}$ خواهد بود.

تکرار (Iteration):

- در هر گام، الگوریتم تمام جفت‌های متوالی مانند $((c, a), (a, t), (c, a), (a, r))$ را در کل پیکره شمارش می‌کند.
 - جفتی که بیشترین تکرار را دارد، انتخاب می‌شود.
 - یک توکن جدید با ادغام این جفت ایجاد می‌شود (مثلاً اگر (t, h) پرتکرارترین باشد، توکن th ایجاد می‌شود).
 - تمام نمونه‌های آن جفت در پیکره با توکن جدید جایگزین می‌شوند.
 - این فرآیند تا زمانی که اندازه واژگان به V برسد، تکرار می‌شود.
- در زمان توکن‌سازی متن جدید، BPE آن را با حریصانه‌ترین (طولانی‌ترین) زیرواژه‌های ممکن از سمت چپ به راست تقسیم می‌کند. به عنوان مثال، اگر **tokenization** را بخواهد توکن‌سازی کند و در واژگانش **token** و **tok** وجود داشته باشد، **token** را انتخاب می‌کند.

اگر کاراکتری در واژگان پایه نباشد، به یک توکن ناشناخته (**[UNK]** یا "unknown token") تبدیل می‌شود. این مشکل در مدل‌هایی مانند **GPT-2** و **RoBERTa** با استفاده از **BPE در سطح بایت (byte-level BPE)** حل شده است تا اطمینان حاصل شود که تمام کاراکترهای ممکن در واژگان پایه گنجانده شده‌اند.

Byte-Level BPE

Byte-Level BPE این مشکل را با تغییر واحد پایه از **کاراکترهای یونیکد** به **بایت‌ها** حل می‌کند. هر کاراکتر یونیکد، در نهایت به یک یا چند بایت در سیستم‌های کامپیوتری تبدیل می‌شود (با استفاده از یک کدگذاری مانند **UTF-8**). تعداد بایت‌های ممکن فقط ۲۵۶ تا است (از ۰ تا ۲۵۵).

تبدیل به بایت: اولین قدم در BPE در سطح بایت، تبدیل کل متن به رشته‌ای از بایت‌ها است. برای مثال، کلمه Hello در UTF-8 به بایت‌های [72, 101, 108, 108, 111] تبدیل می‌شود. حتی یک ایموجی 🌟 هم به چندین بایت تبدیل می‌شود، مثلاً [226, 156, 172].

یادگیری ادغام‌ها: الگوریتم BPE حالا نه بر روی H و e، بلکه بر روی جفت بایت‌های متوالی مانند (72, 101) عمل می‌کند. این الگوریتم، پرکاربردترین جفت‌های بایت را پیدا کرده و آن‌ها را به یک توکن جدید ادغام می‌کند. این فرآیند ادامه می‌یابد تا به اندازه واژگان مطلوب برسد.
